

# ESPECIALIZACIÓN EN MACHINE LEARNING ENGINEER


**Tema: Fundamentos de MLE** 

Sesión 4

**Docente: Arnaldo Alvarado** 

## ¿Qué es AutoML?

El Machine Learning Automatizado (**AutoML**) representa un conjunto de procesos y técnicas que permiten la **automatización de tareas** relacionadas con el aprendizaje automático. Su objetivo es hacer que el Machine Learning sea más accesible, reduciendo o eliminando la necesidad de **expertise especializado en ciertas etapas** del proceso de modelado. Esto incluye desde la preparación de los datos, selección de modelos, hasta la optimización de hiperparámetros.





## **PyCaret: Conceptos**

PyCaret es una **biblioteca de AutoML en Python** que ofrece una interfaz de alto nivel para varias bibliotecas y frameworks de ML, como scikit-learn, XGBoost, LightGBM, y otros. Está diseñada para **automatizar el flujo de trabajo de Machine Learning**, permitiendo a los usuarios pasar de la preparación de datos a la implementación de modelos en pocas líneas de código.

**Simplicidad:** PyCaret está diseñado para ser **simple y fácil de usar**. Los usuarios pueden realizar tareas complejas de ML con un **mínimo esfuerzo y conocimiento técnico**.

**Eficiencia:** Permite a los usuarios **experimentar y comparar docenas de modelos** y técnicas de preprocesamiento de forma rápida y eficiente.

Flexible: Aunque es de alto nivel y fácil de usar, PyCaret no sacrifica la flexibilidad. Los usuarios pueden personalizar el pipeline de ML según sea necesario.

**Integrado:** Soporta tareas de clasificación, regresión, clustering, detección de anomalías, procesamiento de lenguaje natural (NLP), y más, todo dentro de un marco unificado.

#### Instalación



## **PyCaret: Conceptos**

#### Preparación de datos

La calidad de los datos de entrada es **fundamental para el éxito de cualquier proyecto** de Machine Learning. La preparación de los datos implica varios pasos críticos para asegurar que tus **modelos funcionen correctamente** y sean capaces de generar **predicciones precisas.** 

Limpieza de datos: Elimina o corrige registros corruptos o inexactos de tus datos. Esto puede incluir el manejo de valores faltantes, la eliminación de duplicados, o la corrección de errores de formato.

**Transformación de datos:** Convierte los datos a un **formato adecuado** para el modelado. Esto puede implicar la **normalización o estandarización** de las características numéricas, la **codificación de variables categóricas**, y la **transformación de fechas** y otros tipos de datos en formatos útiles.

**Selección de features:** Identifica las **características más relevantes** para tu problema. Esto puede implicar el **análisis de la correlación** entre diferentes características y la etiqueta objetivo, así como la eliminación de características redundantes o irrelevantes.

**División de datos:** Divide tus datos en **conjuntos de entrenamiento y prueba** (y, opcionalmente, de validación). Esto es crucial para evaluar el rendimiento de tus modelos de manera objetiva, entrenándolos en un conjunto de datos y probándolos en otro distinto.

PyCaret simplifica muchos de estos pasos con su función setup. la cual realiza automáticamente muchas tareas de preprocesamiento y validación de datos, permitiéndote especificar tus requisitos y preferencias a través de parámetros. Sin embargo, es importante realizar un análisis exploratorio de datos (EDA) antes de este paso para entender tus datos determinar las transformaciones limpiezas necesarias.



Paso 1: Cargar dataset

PyCaret ofrece datasets de muestra que pueden ser cargados directamente. Para cargar el dataset de Iris:

```
from pycaret.datasets import get_data
dataset = get_data('iris')
```

|   | sepal_length | sepal_width | petal_length | petal_width | species     |
|---|--------------|-------------|--------------|-------------|-------------|
| 0 | 5.1          | 3.5         | 1.4          | 0.2         | Iris-setosa |
| 1 | 4.9          | 3.0         | 1.4          | 0.2         | Iris-setosa |
| 2 | 4.7          | 3.2         | 1.3          | 0.2         | Iris-setosa |
| 3 | 4.6          | 3.1         | 1.5          | 0.2         | Iris-setosa |
| 4 | 5.0          | 3.6         | 1.4          | 0.2         | Iris-setosa |

Si quieres importar tus propios datos, puedes utilizar pandas y luego pasar el DataFrame a PyCaret:

```
import pandas as pd
dataset = pd.read_csv('mi_dataset.csv')
```



#### Paso 2: Configuración del experimento

Para inicializar el entorno en PyCaret y configurar el experimento, usamos setup(). Este paso es crucial ya que prepara los datos para el modelado y establece las bases del experimento.

https://pycaret.readthedocs.io/en/stable/api/classification.html

|    | Description                 | Value                                                 |
|----|-----------------------------|-------------------------------------------------------|
| 0  | Session id                  | 123                                                   |
| 1  | Target                      | species                                               |
| 2  | Target type                 | Multiclass                                            |
| 3  | Target mapping              | Iris-setosa: 0, Iris-versicolor: 1, Iris-virginica: 2 |
| 4  | Original data shape         | (150, 5)                                              |
| 5  | Transformed data shape      | (150, 5)                                              |
| 6  | Transformed train set shape | (105, 5)                                              |
| 7  | Transformed test set shape  | (45, 5)                                               |
| 8  | Numeric features            | 4                                                     |
| 9  | Preprocess                  | True                                                  |
| 10 | Imputation type             | simple                                                |
| 11 | Numeric imputation          | mean                                                  |
| 12 | Categorical imputation      | mode                                                  |
| 13 | Fold Generator              | StratifiedKFold                                       |
| 14 | Fold Number                 | 10                                                    |
| 15 | CPU Jobs                    | -1                                                    |
| 16 | Use GPU                     | False                                                 |
| 17 | Log Experiment              | False                                                 |
| 18 | Experiment Name             | clf-default-name                                      |
| 19 | USI                         | 079f                                                  |



#### Paso 3: Comparación de modelos

Para comparar diferentes modelos y encontrar el de mejor rendimiento según una métrica determinada, utilizamos compare\_models().

```
from pycaret.classification import compare_models
best_model = compare_models()
```

|          | Model                           | Accuracy | AUC    | Recall | Prec.  | F1     | Kappa  | MCC    | TT (Sec) |
|----------|---------------------------------|----------|--------|--------|--------|--------|--------|--------|----------|
| lr       | Logistic Regression             | 0.9718   | 0.0000 | 0.9718 | 0.9780 | 0.9712 | 0.9573 | 0.9609 | 0.8210   |
| knn      | K Neighbors Classifier          | 0.9718   | 0.0000 | 0.9718 | 0.9780 | 0.9712 | 0.9573 | 0.9609 | 0.4020   |
| qda      | Quadratic Discriminant Analysis | 0.9718   | 0.0000 | 0.9718 | 0.9780 | 0.9712 | 0.9573 | 0.9609 | 0.0150   |
| lda      | Linear Discriminant Analysis    | 0.9718   | 0.0000 | 0.9718 | 0.9780 | 0.9712 | 0.9573 | 0.9609 | 0.0150   |
| lightgbm | Light Gradient Boosting Machine | 0.9536   | 0.0000 | 0.9536 | 0.9634 | 0.9528 | 0.9298 | 0.9356 | 0.1000   |
| nb       | Naive Bayes                     | 0.9445   | 0.0000 | 0.9445 | 0.9525 | 0.9438 | 0.9161 | 0.9207 | 0.0110   |
| et       | Extra Trees Classifier          | 0.9445   | 0.0000 | 0.9445 | 0.9586 | 0.9426 | 0.9161 | 0.9246 | 0.0530   |
| gbc      | Gradient Boosting Classifier    | 0.9355   | 0.0000 | 0.9355 | 0.9416 | 0.9325 | 0.9023 | 0.9083 | 0.0990   |
| dt       | Decision Tree Classifier        | 0.9264   | 0.0000 | 0.9264 | 0.9502 | 0.9201 | 0.8886 | 0.9040 | 0.0100   |
| rf       | Random Forest Classifier        | 0.9264   | 0.0000 | 0.9264 | 0.9343 | 0.9232 | 0.8886 | 0.8956 | 0.0720   |
| ada      | Ada Boost Classifier            | 0.9155   | 0.0000 | 0.9155 | 0.9401 | 0.9097 | 0.8720 | 0.8873 | 0.0370   |
| ridge    | Ridge Classifier                | 0.8227   | 0.0000 | 0.8227 | 0.8437 | 0.8186 | 0.7320 | 0.7454 | 0.0110   |
| svm      | SVM - Linear Kernel             | 0.7618   | 0.0000 | 0.7618 | 0.6655 | 0.6888 | 0.6333 | 0.7048 | 0.0150   |
| dummy    | Dummy Classifier                | 0.2864   | 0.0000 | 0.2864 | 0.0822 | 0.1277 | 0.0000 | 0.0000 | 0.0100   |



Paso 4: Creación de un modelo específico

Si tienes interés en un modelo específico, puedes crearlo directamente. Por ejemplo, para entrenar un modelo de Árbol de Decisión:

```
from pycaret.classification import
create_model
dt = create_model('lr')
```

'Ir' se refiere a Logistic Regression. Cada tipo de modelo tiene una identificación específica en PyCaret.

|      | Accuracy | AUC    | Recall | Prec.  | F1     | Карра  | MCC    |
|------|----------|--------|--------|--------|--------|--------|--------|
| Fold |          |        |        |        |        |        |        |
| 0    | 0.8182   | 0.0000 | 0.8182 | 0.8788 | 0.8061 | 0.7250 | 0.7642 |
| 1    | 0.9091   | 0.0000 | 0.9091 | 0.9273 | 0.9076 | 0.8625 | 0.8735 |
| 2    | 0.9091   | 0.0000 | 0.9091 | 0.9273 | 0.9076 | 0.8625 | 0.8735 |
| 3    | 0.7273   | 0.0000 | 0.7273 | 0.8442 | 0.6826 | 0.5875 | 0.6674 |
| 4    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 5    | 0.9000   | 0.0000 | 0.9000 | 0.9250 | 0.8971 | 0.8485 | 0.8616 |
| 6    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 7    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 8    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 9    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| Mean | 0.9264   | 0.0000 | 0.9264 | 0.9502 | 0.9201 | 0.8886 | 0.9040 |
| Std  | 0.0893   | 0.0000 | 0.0893 | 0.0552 | 0.1011 | 0.1351 | 0.1119 |
|      |          |        |        |        |        |        |        |



Paso 5: Optimización de hiperparámetros

Para optimizar los hiperparámetros de un modelo y mejorar su rendimiento, utilizamos tune\_model().

from pycaret.classification import tune\_model
tuned\_dt = tune\_model(dt, optimize = 'Accuracy')

Esto intentará diferentes combinaciones de hiperparámetros para el Árbol de Decisión (dt) y se centrará en optimizar la precisión ('Accuracy').

|      | Accuracy | AUC    | Recall | Prec.  | F1     | Карра  | MCC    |
|------|----------|--------|--------|--------|--------|--------|--------|
| Fold |          |        |        |        |        |        |        |
| 0    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 1    | 0.9091   | 0.0000 | 0.9091 | 0.9273 | 0.9076 | 0.8625 | 0.8735 |
| 2    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 3    | 0.7273   | 0.0000 | 0.7273 | 0.8442 | 0.6826 | 0.5875 | 0.6674 |
| 4    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 5    | 0.9000   | 0.0000 | 0.9000 | 0.9250 | 0.8971 | 0.8485 | 0.8616 |
| 6    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 7    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 8    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| 9    | 1.0000   | 0.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 | 1.0000 |
| Mean | 0.9536   | 0.0000 | 0.9536 | 0.9696 | 0.9487 | 0.9298 | 0.9402 |
| Std  | 0.0843   | 0.0000 | 0.0843 | 0.0510 | 0.0967 | 0.1276 | 0.1049 |
|      |          |        |        |        |        |        |        |




#### Paso 6: Visualización del modelo

PyCaret facilita la visualización de diferentes aspectos de un modelo entrenado. Por ejemplo, para visualizar la matriz de confusión del modelo optimizado:

```
from pycaret.classification import plot_model
plot_model(tuned_dt, plot = 'confusion_matrix')
```

PyCaret soporta una variedad de tipos de gráficas que pueden ser especificadas con el parámetro plot. Algunas opciones incluyen 'auc' para la curva ROC, 'feature' para la importancia de las características, entre otras.






#### Paso 7: Evaluación exhaustiva del modelo

Para una evaluación más detallada que incluya varias métricas y gráficas, PyCaret ofrece evaluate\_model.

```
from pycaret.classificationimport plot_model
plot_model(tuned_dt, plot = 'confusion_matrix')
```

Esto abrirá una interfaz de usuario en tu navegador o Jupyter notebook (dependiendo de tu entorno de trabajo) que te permitirá explorar diferentes aspectos del modelo seleccionado.





#### Paso 8: Finalizar el modelo

Una vez que estés satisfecho con el rendimiento del modelo, puedes "finalizarlo". Esto entrena el modelo en el conjunto completo de datos (incluyendo el conjunto de prueba).

```
from pycaret.classification import finalize_model
final_dt = finalize_model(tuned_dt)
```

El modelo finalizado final\_dt está listo para ser usado en producción o para hacer predicciones sobre nuevos datos.

#### Paso 9: Realizar predicciones

Con el modelo finalizado, puedes hacer predicciones sobre nuevos datos. Para demostración, vamos a predecir las etiquetas del mismo conjunto de datos de Iris:

```
from pycaret.classification import predict_model
predictions = predict_model(final_dt, data=dataset)
```

"predictions" incluirá las etiquetas predichas junto con los datos originales.



Paso 10: Guardar y cargar modelos

Finalmente, puedes guardar tu modelo para uso futuro y luego cargarlo cuando sea necesario.

#### Guardar modelo

```
from pycaret.classification import save_model
save_model(final_dt, 'final_dt_model_iris')
```


#### Cargar modelo

```
from pycaret.classification import load_model
loaded_model = load_model('final_dt_model_iris')
```

El modelo guardado final\_dt\_model\_iris puede ser cargado en cualquier momento para hacer predicciones sobre nuevos conjuntos de datos sin necesidad de reentrenar el modelo.




### Azure: Crear cuenta en Azure






## Azure: Crear cuenta de Azure










## **Azure: Conceptos**

#### Subscription

Una suscripción en Azure representa un **acuerdo con Microsoft** para utilizar sus servicios de nube. Esencialmente, actúa como un **contenedor en el que se alojan los recursos** de Azure utilizados. Al crear una suscripción, se **acuerda pagar por los recursos** que consume o por un nivel de servicio específico, según el tipo de suscripción que elija.

#### Resource Group


En Azure, un "Resource Group" o Grupo de Recursos es un **contenedor que alberga recursos relacionados para una solución de Azure.** Los recursos son elementos de Azure como aplicaciones web, bases de datos, cuentas de almacenamiento, redes virtuales, etc. Un Grupo de Recursos es una forma de organizar estos recursos en la arquitectura de Azure, facilitando su gestión, monitoreo y acceso al control.






# **Azure ML: Crear workspace**










# **Azure ML: Crear workspace**




| Basics   | Networking         | Encryption        | Identity                | Tags      | Review + create                                                                                                                 |
|----------|--------------------|-------------------|-------------------------|-----------|---------------------------------------------------------------------------------------------------------------------------------|
| Data er  | ncryption          |                   |                         |           |                                                                                                                                 |
|          |                    |                   |                         |           | an Azure Cosmos DB instance where all data is encrypted at<br>keys. You may choose to bring your own (customer-managed)         |
| Encrypti | on type ①          |                   | <ul><li>Micro</li></ul> | soft-mana | aged keys                                                                                                                       |
|          |                    |                   | Custo                   | mer-mana  | aged keys                                                                                                                       |
| У        |                    | estimate the cos  | t, use the Azu          |           | scription will be higher because of the additional resources in calculator. To learn more, see <u>Use customer-managed keys</u> |
| -        | azore maerime zeon | mig i microsore o | 000                     |           |                                                                                                                                 |

|                                                                                                                                                              | ncryption Identity Tags Review + create                                                                                                                                                                             |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Managed identity                                                                                                                                             |                                                                                                                                                                                                                     |
|                                                                                                                                                              | zure resources to authenticate to cloud services without storing credentials in code. Once<br>ions can be granted via Azure role-based access control. A workspace can be given either a<br>user assigned identity. |
| Identity type                                                                                                                                                | System assigned identity                                                                                                                                                                                            |
|                                                                                                                                                              | User assigned identity                                                                                                                                                                                              |
| Storage account access                                                                                                                                       |                                                                                                                                                                                                                     |
| Azure machine learning allow default storage account. Whe                                                                                                    | s you to choose between credential-based or identity-based access when connecting to the<br>using identity-based authentication, the Storage Blob Data Contributor role must be granted                             |
| Azure machine learning allow default storage account. When the workspace managed iden                                                                        | using identity-based authentication, the Storage Blob Data Contributor role must be granted ity on the storage account. Learn more ਹੈ                                                                               |
| Azure machine learning allow default storage account. Whe                                                                                                    | using identity-based authentication, the Storage Blob Data Contributor role must be granted                                                                                                                         |
| Azure machine learning allow default storage account. When the workspace managed iden                                                                        | using identity-based authentication, the Storage Blob Data Contributor role must be granted ity on the storage account. Learn more of Credential-based access                                                       |
| Azure machine learning allow default storage account. Whe the workspace managed iden Storage account access type  Data impact  If your workspace contains se | using identity-based authentication, the Storage Blob Data Contributor role must be granted ity on the storage account. Learn more of Credential-based access                                                       |


| Basics                    | Networking                            | Encryption                      | Identity     | Tags       | Review + create                                                                          |
|---------------------------|---------------------------------------|---------------------------------|--------------|------------|------------------------------------------------------------------------------------------|
| THE RESERVE OF THE PERSON | name/value pairs<br>resources and re- | AND CONTRACTOR OF THE PERSON OF |              |            | es and view consolidated billing by applying the same tag to $\ensuremath{\mathbb{C}}^3$ |
|                           | t if you croate ta                    | ns and then char                | nae resource | settings o | on other tabs, your tags will be automatically updated.                                  |
| Note tha                  | it ii you create tag                  | go aria tricir criai            | -            |            |                                                                                          |
| Note tha                  |                                       | go and their char               | -            | Va         | lue ①                                                                                    |




# **Azure ML: Crear workspace**







































































## **Azure: Instalar CLI**

https://learn.microsoft.com/en-us/cli/azure/install-azure-cli







#### Step 0: Install dependencies

```
# !pip install azure-identity==1.15.0
# !pip install azureml-fsspec==1.3.1
# !pip install azureml-sdk==1.55.0
# !pip install azure-ai-ml==1.15.0
# !pip install mltable==1.6.1
```

#### Step 1: Set up your workspace

```
from azure.identity import DefaultAzureCredential
from azure.ai.ml import MLClient

credential = DefaultAzureCredential()
ml_client = None
try:

    # Enter details of your Azure Machine Learning workspace
    subscription_id = "suscription-id-413e-b571-e52d252eb3c6"
    resource_group = "dmc-group"
    workspace = "jose-dmc"
    ml_client = MLClient(credential, subscription_id, resource_group, workspace)
except Exception as ex:
    print(ex)
```

#### Step 2: Data source and format

```
import mltable
   paths =
       {'file': './train data/iris dataset.csv'}
   train table = mltable.from delimited files(paths)
   train table.save('./train data')
 ✓ 1.9s
paths:
- file: file://d:\DMC\AutoML Azure\train data\iris dataset.csv
transformations:

    read delimited:

   delimiter: '.'
   empty as string: false
   encoding: utf8
    header: all files same headers
   include path column: false
   infer column types: true
    partition size: 20971520
   path column: Path
   support multi line: false
type: mltable
```



Step 3: Create a Compute Instance (If not exist)

```
# #Sign into Azure with Azure CLI
   # !az login
   0.0s
                                                                                 Python
   ci basic name = "jose-basic-ci"
   from azure.ai.ml.entities import ComputeInstance, AmlCompute
   ci basic = ComputeInstance(name=ci basic name, size="Standard DS2 v2")
   ml client.begin create or update(ci basic).result()
    1m 37.5s
                                                                                 Python
ComputeInstance({'state': 'Running', 'last operation': {'operation name': 'Create', '
```



Step 4: Configure your experiment settings

```
from azure.ai.ml.constants import AssetTypes
from azure.ai.ml import automl, Input
# make an Input object for the training data
my training data input = Input(
   type=AssetTypes.MLTABLE, path="./train data"
classification job = automl.classification(
   compute
                       = ci basic name.
                       = "jose experiment python 3",
   experiment name
   training data
                       = my training data input,
   target column name = "target",
   primary metric
                       = "accuracy",
   n cross validations = 5,
   enable model explainability = True,
                       = {"dmc": "demo"}
     enable early termination=True,
# # Training properties are optional
     blocked training algorithms=["logistic regression"].
```



Step 5: Run experiment

```
# Submit the AutoML job
returned_job = ml_client.jobs.create_or_update(classification_job)

# Get the URL to monitor the job in Azure Machine Learning studio
print(f"Monitor your job at {returned_job.studio_url}")

\[
\square 10.2s
\]

Monitor your job at <a href="https://ml.azure.com/runs/quirky_star_nktb75xkkp?wsi">https://ml.azure.com/runs/quirky_star_nktb75xkkp?wsi</a>
```



